

مقدمة في النماذج اللغوية الكبيرة (LLMs)

Ahmad Masarrat
msratahmad@gmail.com
+962778488438

مقدمة في النماذج اللغوية الكبيرة (LLMs)

ما هي الـ LLMs؟ هي نماذج تعلم آلي (Machine Learning) متطورة تم تدريبها على كميات هائلة من البيانات النصية (Textual Data).

الهدف الأساسي: تمكين البشر السياق، والسرعة

كيف تبني؟

التدريب (Training)

ولماذا هي مميزة؟

تعدد المهام (Multitasking)

تحليل المشاعر
(Sentiment Analysis).

تلخيص المحتوى
(Summarization).

توليد النصوص
(Text Generation)

نشأة الثورة التقنية

بنية المحولات (Transformer Architecture)

بنية شبكة عصبية (Neural Network) متطورة تُستخدم في مهام التعلم الآلي (Machine Learning)، وخاصة في مجالات معالجة اللغات الطبيعية (NLP) و رؤية الحاسوب (Computer Vision)

نشأة الثورة التقنية

نقطة التحول: تم تقديمها في عام 2017 عبر الورقة البحثية الشهيرة
"Attention is All You Need" بواسطة فريق Google (Vaswani et al).

آلية الانتباه (Attention Mechanism).


لماذا احتجنا للمدولات؟

مشاكل النماذج التقليدية (RNNs & LSTMs)

المعالجة التسلسلية
(Sequential Processing)

مشكلة تلاشي الاشتقاق
(Vanishing Gradient Problem)

ذاكرة المدى القصير الطويلة
(LSTMs)
(GRU)



مثال توضيحي لفشل النماذج التقليدية

ارتباط الكلمات البعيدة

"سافر خالد إلى فرنسا.. وفي النهاية التقى برئيس
تلك الدولة"
تلك؟

كلمة مثل "Point" قد تعني "نقطة" أو "يُشير"
السياق؟

بُنية المحولات (Transformer Architecture)

آلية الانتباه الذاتي (Self-Attention Mechanism)

تسمح للنموذج بتحديد مدى "علاقة" كل كلمة بالكلمات الأخرى داخل نفس الجملة.

بُنية المدولات (Transformer Architecture)

النظام المتجهي: يتم تحويل كل كلمة في المتتابة إلى ثلاثة متجهات أساسية (Vectors)

الاستعلام (Query - Q): ما الذي نبحث عنه؟


المفتاح (Key - K): ما هي المعلومات التي تقدمها الكلمة؟

القيمة (Value - V): ما هي المعلومة الفعلية التي سنأخذها؟

$$Attention(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

بُنية المدولات (Transformer Architecture)

الانتباه متعدد الرؤوس (Multi-Head Attention)



بُنية المدولات (Transformer Architecture)

الترميز الموضعي (Positional Encoding)

Sequence		Index of token, k	Positional Encoding Matrix with d=4, n=100			
			i=0	i=0	i=1	i=1
I	→	0	$P_{00}=\sin(0)$ = 0	$P_{01}=\cos(0)$ = 1	$P_{02}=\sin(0)$ = 0	$P_{03}=\cos(0)$ = 1
am	→	1	$P_{10}=\sin(1/1)$ = 0.84	$P_{11}=\cos(1/1)$ = 0.54	$P_{12}=\sin(1/10)$ = 0.10	$P_{13}=\cos(1/10)$ = 1.0
a	→	2	$P_{20}=\sin(2/1)$ = 0.91	$P_{21}=\cos(2/1)$ = -0.42	$P_{22}=\sin(2/10)$ = 0.20	$P_{23}=\cos(2/10)$ = 0.98
Robot	→	3	$P_{30}=\sin(3/1)$ = 0.14	$P_{31}=\cos(3/1)$ = -0.99	$P_{32}=\sin(3/10)$ = 0.30	$P_{33}=\cos(3/10)$ = 0.96


Positional Encoding Matrix for the sequence 'I am a robot'

المشكلة ان ال Transformer يعالج الكلمات دفعة واحدة (Parallel)

الحل في إضافة ترميز موضعي (Positional Encoding) إلى تمثيلات الكلمات (Token Embeddings).


بنية المدولات (Transformer Architecture)

تمثيلات الكلمات (Embeddings)



بنية المدولات (Transformer Architecture)

تمثيلات الكلمات (Embeddings)



بُنية المدولات (Transformer Architecture)


الشبكات المغذية للأمام

(Position-wise Feed-Forward Networks)

تتكون من تحويلين خطيين مع وظيفة تنشيط (Activation Function) من نوع ReLU

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

بُنية المدولات (Transformer Architecture) الشبكات المغذية للأمام (Position-wise Feed-Forward Networks)



ReLU

تضمن عدم خطية النموذج
(Non-linearity)، مما يسمح له
بفهم علاقات معقدة جداً.

بُنية المدولات (Transformer Architecture)

بنية المشفر وفك التشفير

(Encoder-Decoder Architecture)

المشفر (Encoder)

فك التشفير (Decoder)


"Je suis étudiant"

'I am a student'

**يتكون كل جانب من عدة طبقات تحتوي على
الانتباه الذاتي (Self-Attention) و الشبكات
المغذية للأمام (Feed-Forward).**

بنية المدولات (Transformer Architecture)

بنية المشفر وفك التشفير (Encoder-Decoder Architecture)



بُنية المدولات (Transformer Architecture)

أين يحدث الانتباه؟

(Three Types of Attention)

الانتباه الذاتي للمشفّر
(Encoder Self-Attention)

تأتي جميع المتجهات (Q, K, V) من الطبقة السابقة للمشفّر.

يسمح لكل كلمة بالارتباط بكل الكلمات الأخرى في المدخلات لفهم السياق الكامل (Full Context)

الانتباه الذاتي لفك التشفير
(Masked Decoder Self-Attention)

يتم حجب الكلمات المستقبلية (Masked)، بحيث لا يرى النموذج إلا الكلمات السابقة فقط.

هذا يضمن أن عملية التوليد تتم بشكل ذاتي التراجع (Auto-regressive)، أي التنبؤ بكلمة واحدة في كل مرة.

بُنية المدولات (Transformer Architecture)

أين يحدث الانتباه؟

(Three Types of Attention)


انتباه المشفر وفك التشفير

(Encoder–Decoder Attention)


**تأتي الاستعلامات (Queries) من فك التشفير بينما تأتي
المفاتيح (Keys) و القيم (Values) من مخرجات المشفر**

بُنية المدولات (Transformer Architecture)


لمشفر (Encoder) يبني فهماً عميقاً وشاملاً
للمدخلات.
فك التشفير (Decoder) يبني المخرجات
خطوة بخطوة، معتمداً على ما تعلمه
المشفر وعلى ما قام هو بتوليده حتى تلك
اللحظة.




What are LLM Parameters



Temperature




Top-k and
Top-p




Stop
sequences

What are LLM Parameters?




Frequency
and Presence
Penalties



Model size



Number of
tokens



Context
Window

الهلوسة



هندسة الأوامر (Prompt Engineering)

بدون أمثلة
(Zero-shot Prompting)

يعتمد النموذج على المعرفة المسبقة
(Pre-trained Knowledge)

الأوامر بأمثلة قليلة
(Few-Shot Prompting)


يتم فيها تزويد النموذج بعدد قليل جداً
من الأمثلة التوضيحية

هندسة الأوامر **(Prompt Engineering)**

Chain-of-Thought (CoT) Prompting
Self-Consistency Prompting
Zero-Shot Chain-of-Thought Prompting
ReAct (Reasoning + Acting) Prompting
Retrieval-Augmented Prompting

الضبط الدقيق (Fine-tuning)

عملية ضبط نموذج مدرب مسبقاً (Pre-trained Model)



يمكن البحث في "Model Hub" الخاص بـ Hugging Face

نموذج BERT
نموذج GPT
نموذج T5

الضبط الدقيق (Fine-tuning)

مراحل عملية الضبط الدقيق

تحميل النموذج والمجزئ

تجهيز البيانات

تحديد المهمة

التدريب (Model Training)

التقييم

الحفظ

نشر (deploy)

الضبط الدقيق (Fine-tuning)

بنية التكيف منخفض الرتبة (LoRA Architecture)

بدلاً من تغيير النموذج بالكامل، نقوم بإضافة
"تعديلات" صغيرة وذكية بجانب الأوزان الأصلية

الضبط الدقيق (Fine-tuning)

بنية التكيف منخفض الرتبة (LoRA Architecture)

النموذج المدرب مسبقاً (Pre-Trained Backbone)

تجميد الأوزان الأصلية (Frozen Parameters)

مصفوفات الرتبة المنخفضة (Low-Rank Matrices)

الضبط الدقيق (Fine-tuning)

ماذا لو البيانات غير كافية؟

التعلم التعزيزي من التغذية الراجعة البشرية (RLHF)

سؤال-جواب

الضبط الدقيق (Fine-tuning)

ماذا لو البيانات غير كافية؟

تدريب نموذج المكافأة (Reward Model Training)

عدة إجابات لنفس السؤال من الأفضل إلى الأسوأ

الضبط الدقيق (Fine-tuning)

ماذا لو البيانات غير كافية؟

تحسين السياسة (Policy Optimization)

مبدأ التعلم التعزيزي (RL Primer):\

الحالة (State - S): السياق أو السؤال المطروح

الإجراء (Action - A): الإجابات التي يولدها النموذج

المكافأة (Reward - R): إشارة التقييم من نموذج المكافأة

السياسة (π - Policy): استراتيجية النموذج في اختيار الكلمات لإنتاج الإجابة

الضبط الدقيق (Fine-tuning)

ماذا لو البيانات غير كافية؟

خوارزمية التحسين المستقر (Proximal Policy Optimization - PPO)

تقوم بتقييد حجم التعديلات على سلوك النموذج لضمان بقاء التدريب مستقرًا

تمنع النموذج من محاولة "خدع" نظام المكافآت أو إنتاج مخرجات غريبة وشاذة

وكلاء الذكاء الاصطناعي AI Agents واجهات برمجة التطبيقات (APIs)

هذه حقبة البناء!

chatgpt
gemini
Grok
Kimi
Qwen etc

Lovable
V0
Cursor
Antigravity

شكرا!